

Федеральное государственное образовательное бюджетное
учреждение высшего образования

**«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ
РОССИЙСКОЙ ФЕДЕРАЦИИ»
(Финансовый университет)**

**Институт развития профессиональных
компетенций и квалификаций**

ИТОГОВАЯ РАБОТА

Название программы	«Аналитик Данных»
Группа обучения	«AD 8 26.06.26»
Срок обучения	«26.06.2026 — 22.09.2026»
«Шульгина Екатерина Дмитриевна»	
Номер/Название Датасета	«Medical Cost Personal Datasets»

Москва 2026 г.

Содержание

Вступление.....	3
<i>Цель работы</i>	<i>3</i>
<i>Задачи</i>	<i>3</i>
<i>О датасете</i>	<i>3</i>
Предобработка и EDA (Исследовательский анализ данных)	4
<i>Предварительная обработка</i>	<i>4</i>
<i>Матрица корреляций числовых признаков</i>	<i>4</i>
<i>Исследовательский анализ данных (EDA)</i>	<i>6</i>
1. <i>Как курение (smoker) влияет на стоимость страховки (charges)?</i>	<i>6</i>
2. <i>Как возраст (age) коррелирует со стоимостью страховки (charges)?</i>	<i>8</i>
3. <i>Влияют ли индекс массы тела (bmi) и пол (sex) на стоимость (charges)?</i>	<i>11</i>
Обогащение данных и расширенный анализ	13
<i>ABC-анализ</i>	<i>14</i>
<i>XYZ-анализ.....</i>	<i>16</i>
<i>RFM-анализ</i>	<i>16</i>
Визуализация с помощью BI-инструментов	18
Построение и сравнение моделей машинного обучения	19
Заключение.....	22
Ссылки	24

Цель работы

Целью данной работы является демонстрация знаний и навыков, полученных в ходе курса Программы профессиональной переподготовки «Аналитик Данных».

Задачи

1. Следуя принципам ETL, провести подготовку данных и исследовательский анализ данных (EDA)
2. Обогатить данные, проведя ABC-XYZ-анализ и RFM-анализ
3. Построить визуальный отчёт с применением дашбордов
4. Обучить модели машинного обучения и сравнить их качество

О датасете

Для проведения анализа использовался учебный датасет «**Medical Cost Personal Datasets**», расположенный на платформе **Kaggle** (ссылка 1). Данный датасет содержит **1338 строк** с данными записей реальных клиентов (клиентов страховой фирмы), проживающих в США, включая

- **Age** — возраст,
- **Sex** — пол,
- **BMI** — индекс массы тела,
- **Children** — количество детей, чьи приёмы такж покрываются страховкой клиента,
- **Smoker** — является ли клиент курильщиком,
- **Region** — территория проживания
в пределах страны (северо-восток, юго-восток, юго-запад, северо-запад),
- **Charges** — сумма к оплате за лечение, покрываемая страховой компанией клиента.

ПРЕДОБРАБОТКА И EDA (ИССЛЕДОВАТЕЛЬСКИЙ АНАЛИЗ ДАННЫХ)

Предварительная обработка

Предобработка датасета показала, что...

- общее количество строк соответствует заявленному в описании (1338);
- типы соответствуют данным в колонках (числовые: age, bmi, children, charges; категориальные: sex, smoker, region);
- явных пропусков в данных нет;
- диапазоны значений находятся в разумных границах; стоимость услуг показывает весьма значительный разброс.
- был обнаружен и удалён 1 дубликат;
- логических нарушений нет;
- значения категориальных столбцов уникальны; нет дополнительных вариантов ответов, образованных опечатками или лишними пробелами.

Матрица корреляций числовых признаков

Построим матрицу корреляций числовых признаков по Пирсону, прежде чем переходить к анализу конкретных гипотез. Это позволит нам оценить общую картину: какие факторы имеют линейную связь со стоимостью страховки (`charges`), а какие — нет. Категориальные признаки (`smoker`, `sex`, `region`) не участвуют в этом расчете, их влияние мы оценим отдельно с помощью группировок и сравнения распределений.



Вывод:

1. Наибольшую корреляцию со стоимостью страховки (charges) имеет признак возраста (age);
2. На втором месте по влиянию находится индекс массы тела (bmi);
3. Наличие у клиента детей (children) практически никак не влияет на стоимость страховки.

Исследовательский анализ данных (EDA)

Далее попробуем провести **оценку факторов, влияющих на стоимость медицинских услуг (charges), и выявить закономерностей между демографическими показателями и расходами клиентов:**


1. Как курение (`smoker`) влияет на стоимость страховки (`charges`)?
2. Как возраст (`age`) коррелирует со стоимостью?
3. Влияют ли индекс массы тела (`bmi`) и пол (`sex`) на стоимость (`charges`)

1. Как курение (`smoker`) влияет на стоимость страховки (`charges`)?

Согласно статье на сайте американской страховой фирмы Weaver&Associates от 3-го декабря 2025 года, курящим клиентам следует ожидать в 2-3 раза более высокие страховые платежи, т. к. компании, предоставляющие услуги, рассматривают курильщиков как людей с повышенным риском смертности («Expect to pay 2-3 times more for life insurance if you smoke, as carriers view tobacco users as higher mortality risks.», ссылка 4).

Соберём таблицу **по влиянию курения на стоимость страховки** на основе нашего датасета и визуализируем её:

avg_charges	median_charges	std_charges	count	variation_coef
8440,66	7345,73	5992,97	1063	71%
32050,23	34456,35	11541,55	274	36%



Выводы:

1. Курящие клиенты в среднем платят в 4 раза больше некурящих клиентов (32.000 против 8.000), что в целом соответствует нашим ожиданиям;
2. У некурящих клиентов получился очень большой коэффициент вариации, что можно объяснить низкими средними расходами;
3. У курящих клиентов медиана получилась больше среднего, что является нетипичным проявлением. **Гипотеза:** среди курящих есть группа с аномально низкими доходами, которая занижает среднее; предположим, что эта группа состоит из молодых людей с нормальным BMI, которые в целом отличаются более крепким здоровьем, благодаря этим характеристикам.


Проверим эту гипотезу, разделив курящих на две группы: с высокими расходами на страховые выплаты и с низкими. В каждой группе посчитаем средний возраст и индекс массы тела — проверим, действительно ли в группу с низкими расходами в основном попадают более молодые люди, к тому же обладающие здоровой комплекцией (BMI 18.5–25, ссылка 5).

Пусть разделителем служит первый квартиль, тогда 25% — это группа курящих с самыми низкими расходами на страховые выплаты (которые, тем не менее, всё же

выше, чем у среднестатистического некурящего клиента) и, наиболее вероятно, содержащая в основном молодых людей здоровой комплекции, а оставшиеся 75% — курящие клиенты с повышенными расходами.

Группа	Средний возраст	Средний BMI	Средние расходы (\$)	Кол-во человек
Низкие расходы (нижние 25%)	28,2	24,7	17713,7	69
Высокие расходы (верхние 75%)	42	32,7	36875,7	205

Сравнение характеристик курящих с низкими и высокими расходами



Как мы можем видеть, действительно, среди курящих меньше всего страховые платежи у тех клиентов, которые в среднем моложе тех, у которых платежи выше; эти клиенты также, как правило, имеют более здоровую конституцию с индексом массы тела в пределах нормы.

2. Как возраст (age) коррелирует со стоимостью страховки (charges)?

Отообразим зависимость стоимости услуг страховой компании от возраста клиента на диаграмме рассеяния и посчитаем коэффициент корреляции Пирсона, чтобы превратить её в метрику:



Коэффициент корреляции Пирсона (см. таблицу корреляций) выявил слабую/умеренную положительную связь — 0.298 (слабая связь: 0.0 – 0.3; умеренная связь: 0.3 – 0.5).


Оценивая распределение на графике, можно сделать следующие выводы:

1. Есть общая тенденция к повышению стоимости страховки с возрастом (однако, поскольку связь признаков на границе слабой с умеренной, возраст не является главным определяющим фактором в пользу повышения стоимости);

2. Наблюдается разбиение на 3 группы по стоимости; **Гипотеза:** попробуем проверить, связано ли это с тем, что курильщики в среднем платят за страховку больше, и потому мы наблюдаем две похожих по форме распределения в середине.

3. Нижний слой кажется наиболее густым. **Гипотеза:** в среднем, большинство клиентов в нашем датасете имеют относительно небольшие траты по страховке, что также может быть связано с тем, что они не курят и имеют здоровое телосложение.

Проверим наблюдения:



Слой	Кол-во клиентов
Нижний слой (до \$15000)	979
Средний слой (от \$15000 до \$35000)	225
Верхний слой (от \$35000)	133

Курильщики (взносы до \$15000)	Некурящие (взносы до \$15000)
7	972

Действительно, в самом нижнем слое количество клиентов значительно превышает их количество в среднем и верхнем слоях, подтверждая гипотезу о том, что в среднем большинство клиентов всех возрастов тратят на страховку до \$15.000.


Мы также можем видеть, что среди клиентов, платящих до \$15.000 большинство являются некурящими.

3. Влияют ли индекс массы тела (**bmi**) и пол (**sex**) на стоимость (**charges**)?

Чтобы в дальнейшем получился более точный прогноз, посмотрим зависимость стоимости страховки от оставшихся двух демографических показателей нашего датасета — индекса массы тела и пола клиента:

Таблица корреляции показывает зависимость стоимости (**charges**) от индекса массы тела (**bmi**) как 0.198/1.0.

avg_charges	median_charges	avg_bmi	avg_age	count
12569,58	9412,96	30,38	39,5	662
13975	9377,9	30,94	38,95	675




Выводы:

1. В целом, разницы между стоимостью страховки у мужчин и женщин не наблюдается;
2. Медиана снова оказалась выше среднего, что говорит о том, что и среди мужчин, и среди женщин есть группы клиентов со значительно повышенной

стоимостью страховки. **Гипотеза:** возможно, эти клиенты являются курильщиками, что и отразилось бы на повышении стоимости страховки.

Проверим эту гипотезу:

sex	smoker	avg_charges	median_charges	count
female	no	8762,3	7639,42	547
female	yes	30679	28950,47	115
male	no	8099,7	6986,1	516
male	yes	33042,01	36085,22	159



Вывод:

Пол сам по себе не является фактором с сильным влиянием, в отличие от того, является ли клиент курильщиком или нет.

ОБОГАЩЕНИЕ ДАННЫХ И РАСШИРЕННЫЙ АНАЛИЗ

Перейдём от описательного анализа к аналитическому конструированию. Результат в дальнейшем поможет в сборке модели прогнозирования. Посмотрим, какие признаки можно создать на основе имеющихся:

- **age_group (age)** — скомпануем клиентов в возрастные группы для удобства анализа;
- **bmi_category (bmi)** — скомпануем клиентов по категориям в соответствии с медицинским стандартом для этого показателя;
- **high_risk (age + smoker)** — выделим группу максимального риска с наибольшими затратами по страховке;
- **cost_marker (charges)** — флаг-признак для ABC-анализа;
- **is_parent (children)** — флаг-признак для ABC-анализа;

Создадим их и добавим в датасет:

	age	sex	bmi	children	smoker	region	charges	bmi_category	age_group	is_parent	high_risk_flag
0	19	female	27.900	0	yes	southwest	16884.92400	Избыточный вес	Молодые (18-30)	0	0
1	18	male	33.770	1	no	southeast	1725.55230	Ожирение	Молодые (18-30)	1	0
2	28	male	33.000	3	no	southeast	4449.46200	Ожирение	Молодые (18-30)	1	0
3	33	male	22.705	0	no	northwest	21984.47061	Норма	Средний возраст (31-50)	0	0
4	32	male	28.880	0	no	northwest	3866.85520	Избыточный вес	Средний возраст (31-50)	0	0
...	...	...	...	...	...	...	...	...	...	...	...
1332	50	male	30.970	3	no	northwest	10600.54830	Ожирение	Средний возраст (31-50)	1	0
1333	18	female	31.920	0	no	northeast	2205.98080	Ожирение	Молодые (18-30)	0	0
1334	18	female	36.850	0	no	southeast	1629.83350	Ожирение	Молодые (18-30)	0	0
1335	21	female	25.800	0	no	southwest	2007.94500	Избыточный вес	Молодые (18-30)	0	0
1336	61	female	29.070	0	yes	northwest	29141.36030	Избыточный вес	Зрелый возраст (51-64)	0	1


ABC-анализ

ABC-анализ — это метод классификации объектов по их вкладу в общий результат, основанный на Принципе Парето, согласно которому **20% объектов дают 80% результата**. В случае с датасетом «Medical Cost Personal Datasets», клиенты будут разделены на три группы:

- **A** (топ ~20% клиентов) → дают ~80% расходов
- **B** (следующие ~30%) → дают ~15% расходов
- **C** (оставшиеся ~50%) → дают ~5% расходов

С помощью ABC-анализа страховая компания сможет определить группу клиентов с высоким финансовым риском, клиника — выделить клиентов, которым может потребоваться объёмное дорогостоящее лечение; кроме того, это разбиение поможет построить модель для оценки прогноза затрат на страховку.

patients_count	total_charges	avg_charges	median_charges	patients_percent	charges_percent
641	14196572,28	22147,54	17560,38	47,9	80
376	2668811,03	7097,9	7145,98	28,1	15
320	888802,11	2777,51	2662,11	23,9	5





Выявим "Портрет клиента с высоким финансовым риском" для страховой компании:

avg_age	avg_bmi	smokers_percent	high_risk_percent	is_parent_percent	avg_charges
46,28	31,13	42,75	0,1	0,55	22147,54
40,49	30,55	0	0	0,78	7097,9
23,58	29,87	0	0	0,37	2777,51

На всякий случай проверим, верно ли посчитался столбец «smoker_percent»:

group	smoker		percent_yes
	no	yes	
A	367	274	42,7
B	376	0	0
C	320	0	0
Total patients	1337		



Выводы:

- Курение является **критическим фактором**, который автоматически переводит клиента в группу высоких расходов (A);
- Даже если курящий клиент молод и имеет нормальный BMI, его расходы всё равно попадают в топ-20% из-за эффекта курения на стоимость страховки.

- Группы В и С состоят исключительно из некурящих клиентов, различающихся только по возрасту и другим факторам.

Гипотеза:

- Для прогнозирования стоимости страховки статус курения (smoker) является **бинарным переключателем**: если клиент курит, он с вероятностью ~100% попадает в группу высоких расходов (А).
- Это объясняет, почему в EDA мы видели чёткое разделение на "слои" на scatter plot — курение создаёт отдельный кластер высоких расходов независимо от других признаков.

XYZ-анализ

XYZ-анализ классифицирует объекты по стабильности потребления во времени с помощью коэффициента вариации:

- X — стабильный спрос (малые колебания);
- Y — спрос имеет тенденцию/сезонность;
- Z — случайный спрос (высокие колебания).

Для расчёта коэффициента вариации необходим временной ряд, например, данные о расходах одного и того же клиента за несколько лет.

Ограничение: поскольку временные показатели в датасете отсутствуют, провести XYZ-анализ не представляется возможным. Поскольку датасет является настоящим, синтез дополнительных данных в данном случае будет нарушением аналитической этики.

RFM-анализ

RFM-анализ показывает реальную ценность каждого клиента на основе его покупательского поведения/взаимодействия с продуктом или услугой. Ключевые компоненты:

- R (Recency) — давность последней покупки/взаимодействия;

- F (Frequency) — частота покупок/взаимодействий;
- M (Monetary) — сумма расходов.


Для компоненты R требуется конкретная дата, для компоненты F — временной ряд (по несколько транзакций на каждого клиента), а для компоненты M должны быть зафиксированы расходы.

Ограничение: поскольку в используемом датасете имеются данные только для компоненты M, проведение полноценного содержательного RFM-анализа не представляется возможным.

ВИЗУАЛИЗАЦИЯ С ПОМОЩЬЮ BI-ИНСТРУМЕНТОВ

В качестве BI-инструмента для визуализации была выбрана платформа Yandex DataLense. На дашборде представлены:

- - KPI: количество клиентов, средняя и медианная стоимость, доля курящих
- - Распределение клиентов по ABC-группам
- - Зависимость стоимости от BMI (по полу)
- - Взаимосвязь возраста и стоимости (по статусу курения)
- - Фильтры: пол, статус курения, возрастная группа, категория BMI



ПОСТРОЕНИЕ И СРАВНЕНИЕ МОДЕЛЕЙ МАШИННОГО ОБУЧЕНИЯ

Для данного датасета можно построить предсказательную модель, которая будет определять примерные размер страхового платежа с учётом пола, индекса массы тела и наличия у клиента вредных привычек (курильщик: да/нет).

Сравним, как с этой задачей справятся модели, построенные с помощью **линейной регрессии** и по методу **случайного леса (Random Forest)**:

Модель	Метрики качества			Интерпретация
	MAE (Средняя абсолютная ошибка)	RMSE (Корень из среднеквадратичной ошибки)	R ² (Коэффициент детерминации)	
Линейная регрессия	\$ 4398.27	\$ 6070.10	0.799	В среднем модель ошибается в прогнозе стоимости на 4398 \$. Модель объясняет 79.9% вариативности стоимости страховки.
Случайный лес (Random Forest)	\$ 2574.75	\$ 4604.14	0.885	В среднем модель ошибается в прогнозе стоимости на 2575 \$. Модель объясняет 88.5% вариативности стоимости страховки.


Вывод:

Модель по методу Случайного леса (Random Forest) показывает лучший результат: коэффициент детерминации выше на 8.5%, а средняя ошибка прогноза уменьшилась на 1824 \$.


Следовательно, в ситуациях, где критически важна минимизация ошибки, следует использовать сложную модель, так как она дает заметное улучшение точности прогноза.

Посмотрим более глубоко на работу модели Случайного леса (Random Forest).

С помощью библиотек SHAP и PDP определим, какими параметрами/признаками руководствовалась модель при расчётах и как именно они влияют на размер страхового взноса:



Графики частичной зависимости (PDP) — Random Forest



Согласно SHAP-анализу, топ-3 наиболее важных признаков: `smoker_no`, `age`, `smoker_yes`. Признаки `smoker_no` и `smoker_yes` являются техническим артефактом OneHotEncoding и отражают один и тот же фактор — статус курения.

График PDP показал нелинейную зависимость: после BMI ≈ 30 и возраста ≈ 50 лет кривая прогнозируемой стоимости растёт круче.

ЗАКЛЮЧЕНИЕ

На основе учебного датасета «Medical Cost Personal Datasets», содержащего 1338 строк с данными записей реальных клиентов, проживающих в США, была проведена комплексная оценка факторов, влияющих на стоимость медицинских страховок (`charges`), с целью выявления ключевых драйверов расходов и последующего построения прогнозной модели.

В соответствии с задачами итоговой работы по программе «Аналитик Данных», анализ датасета проводился с использованием ETL-подхода к взаимодействию с данными. Был проведён исследовательский анализ (EDA), добавлены новые признаки и проведён ABC-анализ. Проведение XYZ- и RFM-анализов оказалось невозможным в силу отсутствия необходимых временных признаков и распределений, что является ограничением данного датасета. Построение дашборда производилось на платформе Yandex DataLense. Были обучены две предсказательные модели: Линейной регрессии и Случайного леса (random Forest); из которых последняя показала наиболее приемлемую точность, благодаря способности отслеживать нелинейные взаимодействия признаков (что было подтверждено во время анализа с использованием SHAP- и PDP-методов Explainable AI-подхода к машинному обучению).

По итогам анализа были сделаны следующие выводы:

- Статус курения является абсолютным лидером среди факторов стоимости. 100% клиентов-курильщиков (274 чел., ~20.5% выборки) попали в группу А ABC-анализа, которая генерирует ~80% всех расходов.
- Возраст и BMI сами по себе имеют слабую линейную связь со стоимостью, но модель машинного обучения (Random Forest) выявила нелинейные пороги: резкий рост прогнозируемой стоимости начинается при BMI ≈ 30 (граница ожирения по ВОЗ) и возрасте ≈ 50 лет.
- Пол клиента не является самостоятельным драйвером стоимости. Наблюдаемая разница в средних чеках полностью объясняется разной долей курящих среди мужчин и женщин.
- Выявленные пороги (BMI=30, Age=50) имеют четкое медицинское обоснование, что повышает доверие к интерпретируемости модели.
- Для повышения точности прогноза можно было бы инициировать сбор дополнительных признаков (прим. наличие хронических заболеваний, даты обращений к врачу за период от года, причины этих обращений и т. п.).

Работа с этим датасетом позволила мне проверить и закрепить полученные в ходе обучения знания, а также обрести множество новых о сфере аналитики данных и связанных бизнес-процессах. Также в ходе проведения анализа была обнаружена критическая нехватка практических умений (написание кода), что значительно усложнило весь процесс, одновременно с эти подсвечивая зоны для дальнейшего профессионального развития.

1. Датасет на платформе Kaggle:

https://www.kaggle.com/datasets/mirichoi0218/insurance?spm=a2ty_o01.29997173.0.0.501955fbYlalj3

2. Блокнот в Google Colab:

<https://colab.research.google.com/drive/1Qq-YMKXSo5tnQ9BVGwFRflEThOltCJhT?usp=sharing>

3. Дашборд в Yandex DataLense:

https://datalens.yandex/mojl47putvrm5?_share_link=public

4. Статья о зависимости размеров страховых взносов от наличия курения в качестве вредной привычки:

<https://www.weaverinsurance.com/impact-of-smoking-on-life-insurance/>

5. Статья об индексе массы тела из архива ВОЗ:

https://web.archive.org/web/20090509190552/http://apps.who.int/bmi/index.jsp?introPage=intro_3.html